

MAXIMUM LIKELIHOOD ESTIMATION

- Verilen örnekler $(x_i, y_i) \in \mathbb{R}^p \times \{0, 1\}$, $i = 1, \dots, n$, $p(x_i) = P(y_i = 1 \mid x_i)$ olsun ve

$$\log \left(\frac{p(x_i)}{1 - p(x_i)} \right) = \beta^T x_i, \quad i = 1, \dots, n$$

- Katsayıların bir tahminini $\hat{\beta}$ oluşturmak için, maksimum olasılık ilkesini kullanacağız. Yani, örneklerin bağımsızlığını varsayarsak, olasılık $(x_i$ şartına bağlı, $i = 1, \dots, N$)

$$\begin{aligned} L(\beta) &= \prod_{i: y_i=1} p(x_i) \cdot \prod_{i: y_i=0} (1 - p(x_i)) \\ &= \prod_{i=1}^n p(x_i)^{y_i} (1 - p(x_i))^{1-y_i}. \end{aligned}$$

Bu olasılık kriterini maksimize etmek için $\hat{\beta}$ seçeceğiz.

- Bir işlevi maksimize etmenin, bir işlevin günlüğünü maksimize etmekle aynı olduğunu unutmayın (çünkü log monoton artmaktadır). Bu nedenle $\hat{\beta}$, log olasılığını en üst düzeye çıkarmak için eşit olarak seçilir.

$$\ell(\beta) = \sum_{i=1}^n y_i \log p(x_i) + (1 - y_i) \log (1 - p(x_i)).$$

Bunu şu şekilde yeniden düzenlemeye yardımcı olur:

$$\begin{aligned} \ell(\beta) &= \sum_{i=1}^n y_i [\log p(x_i) - \log (1 - p(x_i))] + \log (1 - p(x_i)) \\ &= \sum_{i=1}^n y_i \log \left(\frac{p(x_i)}{1 - p(x_i)} \right) + \log (1 - p(x_i)). \end{aligned}$$

Son olarak, $\log(p(x_i)/(1 - p(x_i))) = x_i^T \beta$ için ve $1 - p(x_i) = 1/(1 + \exp(x_i^T \beta))$, $i = 1, \dots, n$,

$$\ell(\beta) = \sum_{i=1}^n y_i (x_i^T \beta) - \log (1 + \exp(x_i^T \beta)). \quad (1)$$

Regresyon için en küçük kareler kriterinden farklı olarak, bu kriter $\ell(\beta)$ 'nin maksimize edicisi için kapalı form ifadesine sahip olmadığını görebilirsiniz (örneğin, kısmi türevlerini alıp sıfıra eşitlemeyi deneyin). Dolayısıyla $\hat{\beta}$ 'yi bulmak için bir optimizasyon algoritması çalıştırmalıyız.

- Biraz dikkat çekici bir şekilde, tekrarlanan ağırlıklı en küçük kareler regresyonlarını çalıştırarak (1) maksimize edebiliriz! Biraz optimizasyon öğrenmiş olanlarınız için, bu aslında Newton'un yönteminin bir somutlaştırmasıdır. Kriter (1) 'e uygulandığında, bunu yinelemeli olarak yeniden ağırlıklandırılmış en küçük kareler veya IRLS olarak adlandırıyoruz.
- Kısaca: lojistik regresyonda $\hat{\beta}$ tahmini, lineer regresyonda olduğundan daha fazla yer alır, ancak bunu yinelemeli olarak lineer regresyon yazılımı kullanarak yapmak mümkündür.